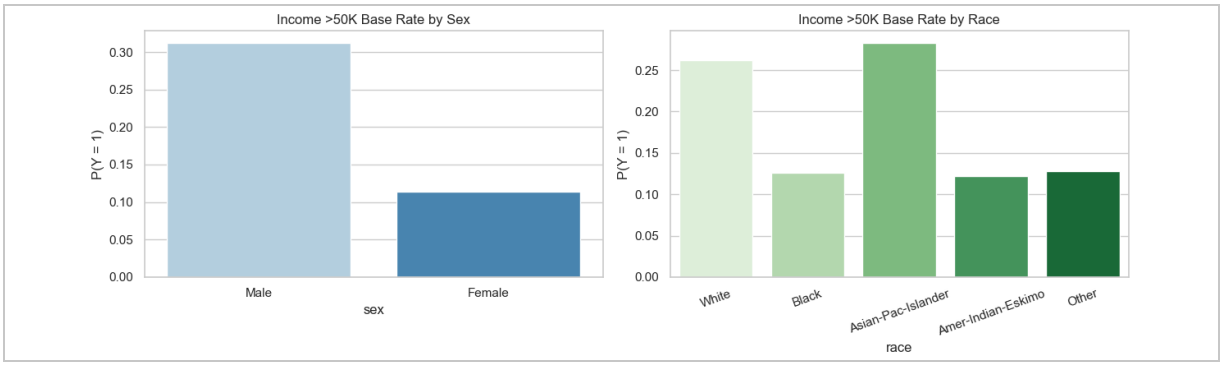
# Perancangan Pipeline Machine Learning yang Adil: Evaluasi Debiasing, Pareto Frontier, dan Akuntabilitas pada Dataset UCI Adult

Gilberto Novena Jemali | NIM 82026006 | AI Security and Ethics (AI104)

Penggunaan machine learning dalam pengambilan keputusan berbasis data menawarkan efisiensi, tetapi sekaligus dapat mempertahankan ketimpangan historis ketika proses pelatihan hanya mengoptimalkan ketepatan prediksi. Karena itu, kualitas model tidak dapat dinilai melalui accuracy saja. Pengukuran fairness perlu memperhatikan apakah probabilitas menerima prediksi positif dan tingkat kesalahan kondisional berbeda antar kelompok yang dilindungi. Literatur menunjukkan bahwa definisi fairness tidak selalu sejalan; pilihan metrik merupakan keputusan teknis sekaligus normatif yang bergantung pada konteks pemanfaatan [2], [3].

Laporan ini mengevaluasi satu pipeline klasifikasi pendapatan berbasis UCI Adult, kemudian membandingkan intervensi debiasing pada tahap pre-processing, in-processing, dan post-processing. Fokus pembahasan mengikuti empat tugas AI104: audit bias pada model dasar, pembobotan ulang data, optimisasi dengan batasan fairness, serta analisis Pareto dan pemilihan satu research operating point. Semua angka yang disampaikan berasal dari output notebook dan empat berkas CSV hasil eksperimen; karena itu angka dinarasikan sebagai hasil pengujian lokal, bukan sebagai temuan yang berlaku universal.

Dataset Adult memuat 48.842 observasi historis hasil ekstraksi sensus Amerika Serikat tahun 1994, dengan sasaran klasifikasi pendapatan tahunan di atas USD 50.000 [1]. Sesudah pembersihan kategori hilang bertanda “?”, tersisa 45.222 data. Sebanyak 34.014 kasus berlabel ≤50K dan 11.208 kasus berlabel >50K, sehingga tingkat kelas positif adalah 24,78%. Perbedaan prevalensi label ini relevan terhadap interpretasi model karena pemisahan tingkat error antarkelompok akan dipengaruhi karakter distribusi data asal.




*Gambar 1. Ruang untuk visualisasi EDA: distribusi target dan pendapatan menurut atribut terlindungi. Sumber: hasil notebook AI104.*

Sejak awal, laporan ini memperlakukan keluaran sebagai prototipe penelitian, bukan alat penentu kelayakan kredit, pekerjaan, atau hak ekonomi. Label pendapatan historis tidak cukup untuk membenarkan kesimpulan mengenai kapasitas, kebutuhan, atau nilai seseorang. Pemisahan antara hasil empiris dan pembenaran etis merupakan prasyarat ketika data sensitif digunakan dalam model prediktif [2], [8].

## Metode Eksperimen dan Audit Bias Model Dasar

Penelitian menerapkan pembagian terstratifikasi sebesar 70% data latih, 15% validasi, dan 15% data uji akhir. Secara numerik, pembagian pada dataset bersih menghasilkan 31.655 data latih, 6.783 data validasi, dan 6.784 data uji. Untuk mengurangi kebocoran selama pengembangan, bagian validasi dipecah menjadi 3.391 kasus kalibrasi dan 3.392 kasus pemilihan model. Encoder untuk fitur kategorikal serta scaler numerik dipelajari hanya dari partisi latih; pemilihan epsilon, threshold, dan model akhir dilakukan tanpa melihat label test set. Implementasi menggunakan Python 3.11, Fairlearn 0.15.0, scikit-learn 1.7.0, dan random seed 42 [6], [9].

Variabel terlindungi utama adalah sex, dengan Male dikodekan A=1 dan Female A=0; race menjadi atribut audit sekunder, disederhanakan sebagai White dan Non-White untuk pemeriksaan interseksional. Penyederhanaan ras tidak boleh dibaca sebagai homogenitas seluruh kelompok non-White. Kolom sex dan race asli sengaja tetap dimasukkan sebagai prediktor dalam eksperimen terkendali ini, sedangkan atribut binernya digunakan untuk audit dan mitigasi. Pemakaian atribut sensitif saat prediksi bukan target leakage secara teknis, tetapi merupakan risiko tata kelola yang memerlukan pertimbangan hukum dan etika khusus [2].

| Kelompok | Jumlah | Proporsi | Base rate >50K |
|---|---|---|---|
| Female | 14.695 | 32,50% | 11,36% |
| Male | 30.527 | 67,50% | 31,25% |
| White | 38.903 | 86,03% | 26,24% |
| Non-White (gabungan) | 6.319 | 13,97% | - |

*Tabel 1. Komposisi kelompok dan prevalensi label positif pada dataset bersih. Sumber: output EDA notebook.*

Model dasar M1 dibangun menggunakan Logistic Regression karena keputusan model dapat dianalisis relatif mudah dan menyediakan skor probabilitas untuk eksperimen threshold. Akurasi M1 pada test set mencapai 0,8467. Namun, probabilitas diprediksi berpendapatan tinggi mencapai 0,2725 pada laki-laki dan hanya 0,0762 pada perempuan. Hasil ini memperlihatkan bahwa performa agregat yang terlihat baik dapat hadir bersamaan dengan ketimpangan antarkelompok.

Tiga ukuran fairness digunakan: Demographic Parity Difference (DPD), yaitu selisih tingkat prediksi positif Male − Female; Disparate Impact Ratio (DIR), yaitu rasio prediksi positif Male/Female; dan Equalized Odds Difference (EOD), yaitu nilai terbesar dari selisih absolut True Positive Rate (TPR) dan False Positive Rate (FPR) antarkelompok [3], [6]. Dengan konvensi ini, M1 menghasilkan DPD=0,1964, DIR=3,5772 dan EOD=0,1197. Semakin kecil |DPD| dan EOD menunjukkan disparitas lebih rendah pada definisi metrik masing-masing; DIR mendekati satu menunjukkan proporsi prediksi positif yang lebih seimbang.

Sumber bias yang dapat ditunjukkan secara deskriptif adalah ketimpangan representasi dan perbedaan base rate kelompok. Tabel silang juga memperlihatkan bahwa kategori relationship = Husband hampir seluruhnya laki-laki dan Wife hampir seluruhnya perempuan, sehingga relationship berpotensi bertindak sebagai proksi. Akan tetapi, pengaruh kausal variabel proksi, bias label historis, maupun amplifikasi oleh algoritma belum terbukti hanya dari audit ini; pengujian ablation atau analisis kontrafaktual dibutuhkan untuk atribusi yang lebih tegas.

## Debiasing Tahap Pre-processing: Instance Re-weighting

Task 2 mengintervensi distribusi efektif sampel pelatihan melalui instance re-weighting. Teknik Kamiran dan Calders memberikan bobot $W(a,y)=P(A=a)P(Y=y)/P(A=a,Y=y)$ sehingga kombinasi kelompok dan label yang kurang terwakili dapat memperoleh kontribusi lebih besar pada fungsi kerugian [4]. Pendekatan ini dipilih karena tidak membuang observasi atau menciptakan contoh sintetis. Bobot dihitung hanya dari training set, sementara evaluasi tetap dilakukan pada distribusi test set yang tidak diubah.

| Atribut sex | Label target | Bobot pelatihan |
|---|---|---|
| Female | ≤50K | 0,8485 |
| Female | >50K | 2,1825 |
| Male | ≤50K | 1,0940 |
| Male | >50K | 0,7931 |

*Tabel 2. Bobot instance re-weighting yang diestimasi pada data latih. Sumber: output Task 2.*

Berdasarkan Tabel 2, contoh perempuan dengan pendapatan >50K diberi bobot sebesar 2,1825, sedangkan contoh laki-laki pada label yang sama memperoleh bobot 0,7931. Pengaturan ini berupaya mengurangi ketergantungan antara atribut sensitif dan label pada distribusi pelatihan tertimbang. Namun, proses pembobotan tidak mengubah struktur penyebab sosial dari pendapatan dan tidak menjamin seluruh metrik fairness membaik secara bersamaan.

| Indikator test set | M1 Baseline | M2 Re-weighting | Perubahan |
|---|---|---|---|
| Accuracy | 0,8467 | 0,8402 | −0,65 pp |
| \|DPD\| | 0,1964 | 0,0944 | −51,93% |
| DIR Male/Female | 3,5772 | 1,7329 | Mendekati 1 |
| EOD | 0,1197 | 0,1589 | +32,75% |

*Tabel 3. Perbandingan model dasar dan re-weighting pada held-out test set. Sumber: evaluation_metrics_summary.csv.*

Poin pentingnya adalah adanya pertukaran ukuran keadilan. Penurunan |DPD| dari 0,1964 menjadi 0,0944 menunjukkan berkurangnya selisih tingkat prediksi positif hingga 51,93%; pada saat yang sama, EOD justru naik dari 0,1197 menjadi 0,1589, atau memburuk sekitar 32,75%. Hal ini terjadi karena demographic parity menilai independensi prediksi terhadap atribut kelompok, sementara equalized odds menilai keseimbangan error setelah mengondisikan pada label sebenarnya. Pada kelompok dengan prevalensi label berbeda, kedua tujuan sering bertentangan bagi classifier informatif [2], [3].

Re-weighting juga menurunkan accuracy sebesar 0,0065 atau 0,65 poin persentase dibandingkan baseline. Meskipun pengorbanan accuracy relatif kecil, hasilnya tidak cukup untuk menyatakan model M2 lebih adil secara umum. Bobot besar pada subkelompok yang relatif kecil dapat meningkatkan sensitivitas terhadap noise dan label historis, sementara pilihan optimisasi lebih dekat dengan demographic parity daripada equalized odds. Dengan demikian, M2 berguna untuk membuktikan efektivitas intervensi pra-pelatihan dan keterbatasan perbaikan metrik tunggal.

## Debiasing Tahap In-processing: Optimisasi Berbatas Fairness

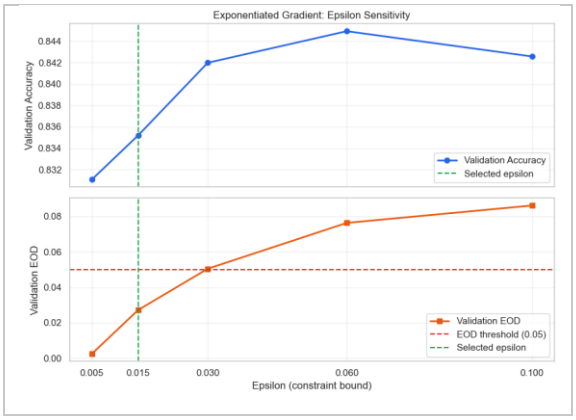
Task 3 menerapkan Exponentiated Gradient (ExpGrad) sebagai strategi in-processing yang mengintegrasikan batasan fairness ke dalam proses pemilihan classifier. Pendekatan reductions mengubah masalah klasifikasi adil menjadi rangkaian submasalah klasifikasi dengan biaya berbeda, kemudian membangun campuran beberapa model dasar [5]. Dua varian dibandingkan: M3a dengan batasan Demographic Parity dan M3b dengan batasan Equalized Odds. Keduanya tidak identik dalam konsekuensi distribusi error karena yang pertama mengutamakan kesetaraan tingkat prediksi positif, sedangkan yang kedua mengutamakan keseimbangan TPR dan FPR.

Pemilihan hyperparameter epsilon bagi M3b dilakukan menggunakan bagian validation selection, bukan test set. Kriteria penelitian didefinisikan sebagai EOD validasi tidak melebihi 0,050, kemudian dipilih accuracy tertinggi di antara konfigurasi yang feasible. Batas ini merupakan ketentuan eksperimen untuk mendemonstrasikan trade-off, bukan ambang universal yang otomatis menentukan legalitas atau etika suatu sistem. Hasil lima konfigurasi yang diuji ditampilkan pada Tabel 4.

| ε | Jumlah submodel | Iterasi akhir | Duality gap | Accuracy val. | EOD val. |
|---|---|---|---|---|---|
| 0.005 | 13 | 7 | 0.0005 | 0.8311 | 0.0024 |
| 0.015 | 12 | 6 | 0.0009 | 0.8352 | 0.0272 |
| 0.030 | 17 | 5 | 0.0000 | 0.8420 | 0.0504 |
| 0.060 | 16 | 5 | 0.0001 | 0.8449 | 0.0763 |
| 0.100 | 6 | 5 | 0.0000 | 0.8426 | 0.0861 |

*Tabel 4. Sensitivitas epsilon pada ExpGrad–Equalized Odds, berdasarkan validation selection. Sumber: epsilon_sensitivity_validation.csv.*

Epsilon 0,015 dipilih karena accuracy validasinya 0,8352 dengan EOD 0,0272. Epsilon 0,005 memang menghasilkan EOD jauh lebih rendah (0,0024), tetapi accuracy lebih rendah, yakni 0,8311. Sebaliknya, epsilon 0,030 menawarkan accuracy 0,8420, tetapi EOD 0,0504 sudah melampaui syarat yang ditetapkan. Peningkatan kelonggaran batas pada konfigurasi berikutnya memperbesar disparitas dengan keuntungan akurasi yang tidak selalu monoton. Nilai duality gap tersimpan antara 0,0000–0,0009 dan iterasi akhir 5–7; hasil ini merupakan indikator berhentinya prosedur optimisasi, bukan jaminan generalisasi fairness pada populasi lain.




*Gambar 2. Ruang grafik sensitivitas epsilon. Sumber: output eksperimen in-processing; dapat dibuat dari epsilon_sensitivity_validation.csv.*

Pada test set, M3a mencapai accuracy 0,8297, |DPD| 0,0257, dan EOD 0,2979; artinya pengurangan disparitas demographic parity yang besar dibayar dengan ketidakseimbangan error kondisional. M3b

menghasilkan accuracy 0,8367 dan EOD 0,0316, sehingga lebih sesuai dengan prioritas equalized odds. Meski demikian, prediksi campuran yang dapat melibatkan randomisasi perlu mempertimbangkan konsistensi prosedural ketika digunakan pada keputusan individual [5].

## Debiasing Tahap Post-processing dan Pemilihan Kandidat

Task 4 menyesuaikan keputusan setelah proses pelatihan tanpa mengubah bobot model dasar. M4a menerapkan Fairlearn ThresholdOptimizer dengan objektif equalized odds, sedangkan M4b menggunakan pencarian threshold terpisah untuk perempuan dan laki-laki. Model dasar post-processing adalah M1, dipilih berdasarkan kriteria dan evaluasi di partisi selection validation sebagai penyedia skor probabilitas. Proses pencarian threshold dilakukan pada 3.391 data kalibrasi agar tidak menggunakan label test sebagai bahan optimisasi [3], [6].

Untuk M4b, threshold kalibrasi yang ditemukan adalah 0,525 pada kelompok Female dan 0,625 pada kelompok Male. Pada calibration set, accuracy tercatat 0,8487 dan EOD 0,0362. Perbedaan batas keputusan tersebut merupakan intervensi nyata: individu yang menghasilkan skor probabilitas sama dapat menerima prediksi berbeda jika berada dalam kelompok yang menggunakan threshold berlainan. Maka, determinisme prediksi M4b tidak sama dengan jaminan keadilan individual; penerapan model berbasis atribut sensitif memerlukan pembenaran serta pengawasan khusus.

| Model | Accuracy val. | EOD val. | Memenuhi EOD ≤0,05 |
|---|---|---|---|
| M1 | 0.8426 | 0.0861 | Tidak |
| M2 | 0.8440 | 0.1687 | Tidak |
| M3a | 0.8328 | 0.2837 | Tidak |
| M3b | 0.8352 | 0.0272 | Ya |
| M4a | 0.8328 | 0.0124 | Ya |
| M4b | 0.8473 | 0.0304 | Ya |

*Tabel 5. Pemilihan model berdasarkan validation selection, bukan test set. Sumber: validation_model_selection.csv.*

Dari enam kandidat pada Tabel 5, hanya M3b, M4a, dan M4b yang memenuhi syarat EOD validasi ≤0,050. Kandidat M4b memperoleh accuracy validasi tertinggi, yaitu 0,8473, dengan EOD 0,0304. Oleh karena itu, M4b ditetapkan sebagai satu-satunya research operating point sesuai aturan seleksi yang ditentukan. Keputusan ini tidak disimpulkan dari tabel test set dan tidak menyiratkan bahwa M4b selalu paling etis untuk seluruh konteks penggunaan.

| Model | Accuracy test | \|DPD\| test | DIR Male/Female | EOD test |
|---|---|---|---|---|
| M1 | 0.8467 | 0.1964 | 3.5772 | 0.1197 |
| M2 | 0.8402 | 0.0944 | 1.7329 | 0.1589 |
| M3a | 0.8297 | 0.0257 | 1.1603 | 0.2979 |
| M3b | 0.8367 | 0.1222 | 2.0739 | 0.0316 |
| M4a | 0.8264 | 0.0973 | 1.9540 | 0.0399 |
| M4b | 0.8387 | 0.1244 | 2.6720 | 0.0448 |

*Tabel 6. Evaluasi akhir seluruh model pada held-out test set. Sumber: evaluation_metrics_summary.csv.*

Hasil final menunjukkan bahwa M4b mencapai accuracy 0,8387 dan EOD 0,0448, lebih rendah daripada EOD baseline 0,1197. Namun, M3b masih memiliki EOD terendah pada test set (0,0316),

sementara M3a memiliki |DPD| terendah (0,0257). Perbedaan peringkat ini memperlihatkan bahwa "model teradil" tidak dapat ditetapkan tanpa menyebut definisi fairness dan aturan keputusan yang dipakai.

## Analisis Pareto Frontier dan Marginal Fairness Tax

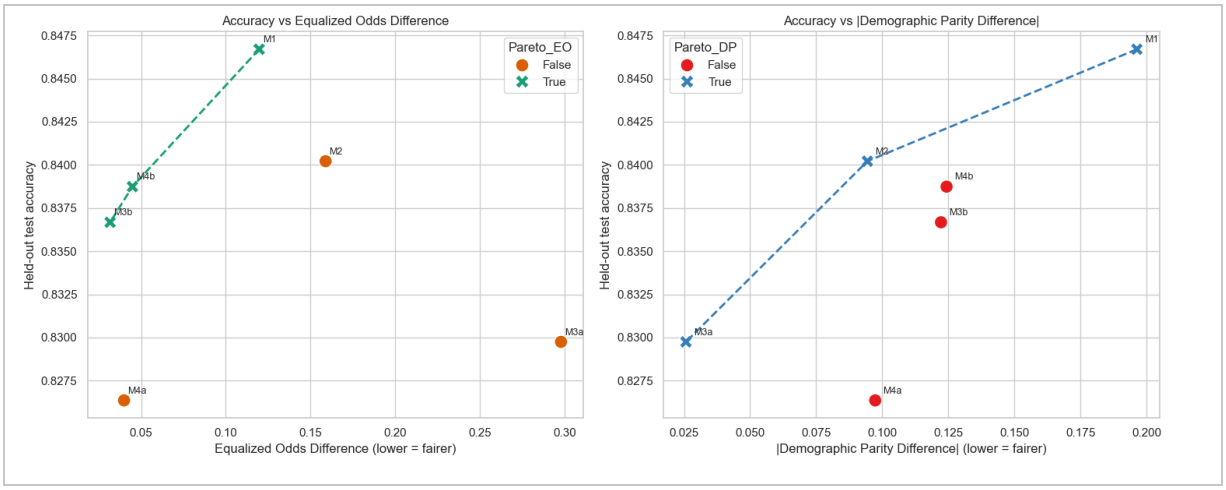
Pareto frontier menilai dua tujuan yang bersaing: memaksimalkan accuracy sekaligus meminimalkan disparitas. Sebuah model dinyatakan Pareto-efficient apabila tidak ada model lain yang setidaknya sama baik pada kedua tujuan dan secara ketat lebih baik pada salah satunya. Dengan EOD sebagai fairness metric utama, data eksperimen menghasilkan tiga titik tidak terdominasi, yaitu M1, M4b, dan M3b. Model M2, M3a, dan M4a berada di luar frontier EOD karena ada alternatif yang unggul atau tidak lebih buruk dalam kedua dimensi.

Frontier diurutkan dari accuracy terbesar menuju EOD terkecil: M1 → M4b → M3b. Perubahan antar titik tersebut digunakan untuk menghitung marginal fairness tax, yaitu besarnya kehilangan accuracy dibagi penurunan EOD. Rasio dihitung dari nilai presisi penuh pada hasil test set, bukan hanya pembulatan empat desimal. Rumusan ini membantu menunjukkan berapa besar pengorbanan prediktif yang dibutuhkan untuk memperoleh pengurangan disparitas tambahan.

| Segmen Pareto | Accuracy turun | EOD turun | Marginal fairness tax |
|---|---|---|---|
| M1 → M4b | 0,007960 (0,80 pp) | 0,074825 | 0,1064 |
| M4b → M3b | 0,002064 (0,21 pp) | 0,013199 | 0,1563 |

*Tabel 7. Perubahan marginal pada frontier Equalized Odds. Sumber: pareto_frontier_analysis.csv.*

Segmen M1 menuju M4b menurunkan EOD sekitar 0,0748 dengan penurunan accuracy sekitar 0,0080; rasio marginalnya 0,1064. Perpindahan berikutnya, M4b menuju M3b, hanya menurunkan EOD tambahan sekitar 0,0132 dan menurunkan accuracy sekitar 0,0021, sehingga rasio meningkat menjadi 0,1563. Peningkatan rasio sekitar 47% dalam sampel model yang diuji menyiratkan diminishing returns lokal pada frontier ini, bukan teorema umum bahwa semua intervensi fairness selalu menunjukkan pola yang sama.




*Gambar 3. Ruang untuk pareto_frontier_comparison.png (dua panel: Accuracy–EOD dan Accuracy–|DPD|). Sumber: hasil proyek AI104.*

Grafik panel kedua dengan |DPD| menunjukkan bahwa frontier berubah ketika definisi fairness diubah: M1, M2, dan M3a berada pada frontier Demographic Parity. Karena itu, keputusan M4b bukan hasil optimasi "fairness universal", melainkan pilihan yang memenuhi prioritas equalized odds,

mempertahankan akurasi relatif tinggi, dan mengikuti aturan validasi yang transparan. Interpretasi Pareto tetap perlu ditempatkan dalam konteks dampak false positive dan false negative yang berbeda [2], [3].

## Operating Point, Model Card, dan Risiko Etis yang Tersisa

M4b dipilih sebagai operating point penelitian karena merupakan model dengan accuracy validasi tertinggi di antara kandidat yang memenuhi ambang EOD 0,050. Pada test set, penurunan EOD dari 0,1197 menjadi 0,0448 setara dengan perbaikan sekitar 62,5%, sedangkan accuracy menurun 0,80 poin persentase dari 84,67% ke 83,87%. Pilihan ini merupakan kompromi terukur, tetapi bukan sertifikasi bebas diskriminasi. DPD yang tersisa sebesar 0,1244 dan DIR Male/Female 2,6720 menunjukkan bahwa proporsi prediksi positif antarkelompok belum seimbang.

Equalized odds diprioritaskan karena ketimpangan false negative dan false positive dapat memberikan dampak berbeda pada individu yang dianalisis. Namun, konteks sebenarnya harus membatasi interpretasi: model dilatih untuk memprediksi label pendapatan historis, bukan untuk mengukur karakter, produktivitas, maupun kelayakan kredit. Orang yang diprediksi berpendapatan tinggi atau rendah tidak boleh langsung diberi atau ditolak hak atas dasar keluaran ini. Pihak terdampak mencakup individu dalam dataset, kelompok rentan pada irisan sex–race, lembaga pengguna, dan pengawas kebijakan [3], [8].

| Komponen model card | Deskripsi model M4b |
|---|---|
| Tujuan penggunaan | Prototipe riset dan audit fairness klasifikasi pendapatan historis. |
| Metode | Logistic Regression + threshold per kelompok; Female 0,525; Male 0,625. |
| Atribut terlindungi | sex (utama); race (sekunder untuk audit interseksional). |
| Hasil test set | Accuracy 0,8387; DPD +0,1244; DIR Male/Female 2,6720; EOD 0,0448. |
| Aturan pemilihan | Accuracy validasi tertinggi, dengan EOD validasi ≤0,050. |
| Penggunaan yang dilarang | Keputusan kredit, rekrutmen, akses bantuan atau layanan tanpa validasi dan tata kelola. |
| Pengawasan | Audit drift, TPR/FPR per kelompok, ukuran sampel, peninjauan manusia dan dokumentasi. |

Tabel 8. Ringkasan model card untuk operating point terpilih, mengikuti prinsip pelaporan model [7].

Audit interseksional pada test set menemukan kelompok Female Non-White berukuran 415 individu, dengan hanya 29 label positif aktual. Pada M4b, tingkat prediksi positif kelompok ini adalah 0,0458, TPR 0,4828, dan FPR 0,0130. Ukuran denominator positif yang kecil menjadikan estimasi TPR rawan variasi sampel. Pada Male White (4.059 individu, 1.323 label positif), selection rate 0,2079 dan TPR 0,4936. Angka tersebut membantu menemukan area yang perlu ditinjau, tetapi tidak membuktikan adanya diskriminasi kausal pada level individu.

Threshold yang berbeda menurut sex menimbulkan persoalan transparansi dan kemungkinan perlakuan berbeda bagi dua orang dengan skor identik. Karena itu, kelebihan determinisme M4b dibanding kebijakan campuran acak M3b tidak otomatis berarti keadilan prosedural lebih tinggi. Sebelum diterapkan dalam sistem nyata, institusi harus memastikan legitimasi penggunaan atribut sensitif, mendefinisikan mekanisme banding, menyediakan human oversight, dan meninjau konsekuensi bagi semua kelompok.

## Keterbatasan Penelitian dan Kesimpulan

Debiasing teknis tidak memperbaiki ketidakrepresentatifan data historis, perbedaan peluang ekonomi, atau makna normatif dari label pendapatan. Dataset tahun 1994 tidak otomatis mencerminkan populasi masa kini. Selain itu, binarisasi race dapat menutupi disparitas di dalam kelompok non-White; ketiadaan pembahasan kausal dan interval kepercayaan membatasi generalisasi. Fairness harus dievaluasi ulang pada data yang sesuai dengan konteks operasi, dengan label baru, pengukuran drift, dokumentasi keputusan, dan pengawasan manusia. Ambang EOD 0,050 pada penelitian ini merupakan kriteria internal eksperimen, bukan standar hukum universal [2], [8].

Kesimpulannya, implementasi penuh Task 1 – 4 berhasil menunjukkan bahwa setiap tahap mitigasi memengaruhi ukuran fairness secara berbeda. Re-weighting memperbaiki demographic parity, ExpGrad–EO mencapai EOD test terkecil, dan perbaikan threshold M4b memberikan kompromi accuracy–fairness yang dipilih secara transparan menggunakan data validasi. Pareto frontier menegaskan tidak adanya satu model yang dominan untuk seluruh tujuan. Hasil akhir layak sebagai demonstrasi akademik yang dapat direproduksi, tetapi belum layak digunakan secara otomatis untuk keputusan sosial atau ekonomi berisiko tinggi.

## Daftar Pustaka

**[1]** B. Becker and R. Kohavi, “Adult,” UCI Machine Learning Repository, 1996. doi: 10.24432/C5XW20. [Online]. Available: https://archive.ics.uci.edu/dataset/2/adult

**[2]** S. Barocas, M. Hardt, and A. Narayanan, Fairness and Machine Learning: Limitations and Opportunities. Cambridge, MA, USA: MIT Press, 2023.

**[3]** M. Hardt, E. Price, and N. Srebro, “Equality of opportunity in supervised learning,” in Advances in Neural Information Processing Systems, vol. 29, 2016.

**[4]** F. Kamiran and T. Calders, “Data preprocessing techniques for classification without discrimination,” Knowledge and Information Systems, vol. 33, pp. 1–33, 2012, doi: 10.1007/s10115-011-0463-8.

**[5]** A. Agarwal, A. Beygelzimer, M. Dudík, J. Langford, and H. Wallach, “A reductions approach to fair classification,” in Proc. 35th Int. Conf. Machine Learning, PMLR, vol. 80, pp. 60–69, 2018.

**[6]** Fairlearn Developers, “Fairlearn documentation: Fairness metrics, reductions, and postprocessing,” ver. 0.15.0, 2026. [Online]. Available: https://fairlearn.org/

**[7]** M. Mitchell et al., “Model cards for model reporting,” in Proc. Conf. Fairness, Accountability, and Transparency, pp. 220–229, 2019, doi: 10.1145/3287560.3287596.

**[8]** E. Tabassi, Artificial Intelligence Risk Management Framework (AI RMF 1.0), NIST AI 100-1, National Institute of Standards and Technology, 2023, doi: 10.6028/NIST.AI.100-1.

**[9]** F. Pedregosa et al., “Scikit-learn: Machine learning in Python,” Journal of Machine Learning Research, vol. 12, pp. 2825–2830, 2011.